Escuta
Voice of Customer Intelligence

RAG com avaliações reais, recuperação híbrida e evidências verificáveis.

BASE ORIGINAL	DOCUMENTOS COM TEXTO	PERÍODO
99.224 avaliações	42.687 documentos	2016–2018

Viviane Demarchi

Relatório técnico complementar · 09 de novembro de 2026

Objetivo

Permitir que gestores investiguem reclamações e elogios em linguagem natural, com acesso aos comentários que sustentam cada achado. O sistema reconhece limitações de escopo e não apresenta a amostra recuperada como uma estatística de toda a base.

Entregas e situação

Código, documentação, auditoria, testes e execuções reais compõem o pacote. Publicação no GitHub e gravação do vídeo dependem da finalização na conta e no computador da aluna. Este PDF não substitui os dois entregáveis exigidos no briefing.

O resultado de avaliação é exploratório. Os resultados não representam uma medição de desempenho geral em produção.

Preservar o sentido e a origem

Foram usados os quatro arquivos oficiais de avaliações, pedidos, itens e produtos. A seleção mantém registros com título ou comentário; a falta de texto não é preenchida artificialmente.

ETAPA / VERIFICAÇÃO	RESULTADO
Registros de avaliação recebidos	99.224
Sem título e sem comentário	56.537
Documentos elegíveis	42.687
Pedidos associados aos documentos	42.540
Ocorrências repetidas de review_id	317
Textos repetidos na base elegível	5.576
Avaliações sem correspondência em pedidos	0

Limpeza conservadora

Remoção de HTML e espaços redundantes; preservação de acentos, pontuação e negações. Email, telefone e CPF identificáveis por padrões são mascarados. Não se alega anonimização completa.

Integração sem inflar a base

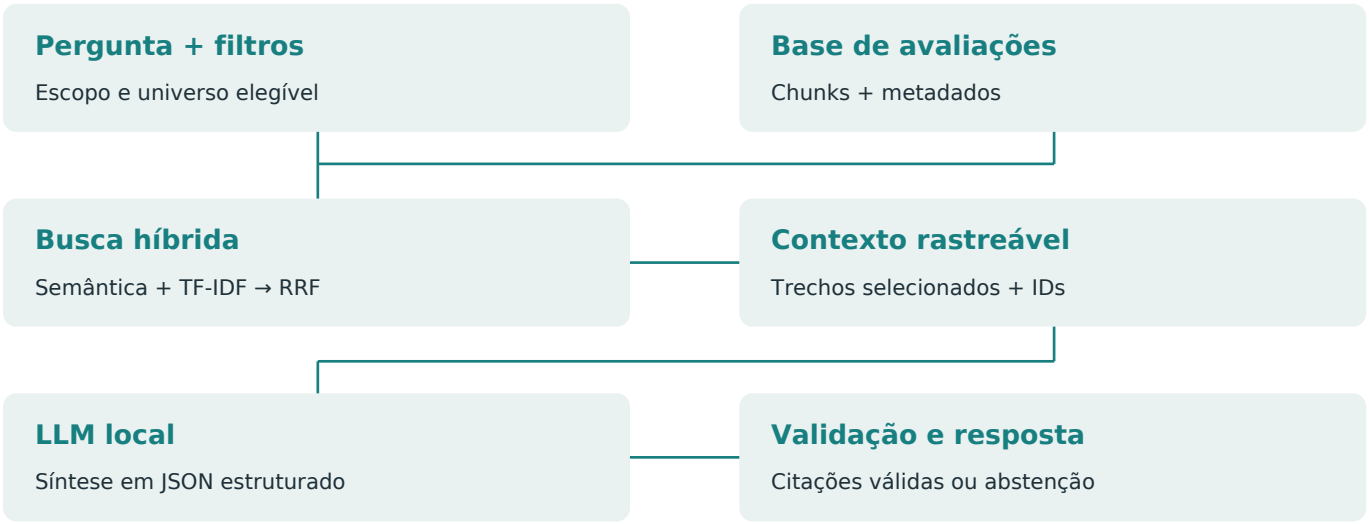
Categorias dos itens são agregadas por pedido antes do join. Relações many-to-one são verificadas. O documento preserva review_id, order_id e posição lógica no CSV; uma chave derivada adicional evita tratar review_id como único.

Metadados e interpretação

Nota, data da compra, lista de categorias e atraso registrado permitem recortes. Pedidos com várias categorias não atribuem o comentário a um produto específico. Ausência de data de entrega permanece desconhecida; atraso compara datas de calendário.

Rastreabilidade: evidence/data_audit.json e evidence/source_sha256.json registram contagens e hashes dos arquivos de origem.

Da pergunta à evidência



DECISÃO	JUSTIFICATIVA
MiniLM multilíngue · 384 dimensões	Representação semântica com suporte a português e execução em CPU.
Chunks: 100 tokens; overlap: 20	Janela de 128 tokens do modelo; evita perder o fim de comentários longos.
Matriz NumPy + busca exata	Escala do protótipo permite simplicidade sem índice aproximado ou serviço externo.
TF-IDF + RRF (constante 60)	Complementa sentidos próximos com termos específicos sem misturar escalas de score.
Qwen2.5 3B Instruct Q4_K_M	Geração local, sem API paga, com limite de capacidade explicitado.

Índice executado: 42.692 trechos para 42.687 documentos. Até seis avaliações entram no contexto. sem repetir documento ou texto.

Filtros são aplicados antes do ranking. Similaridade mínima de 0,30 é uma heurística, não uma probabilidade calibrada. IDs e citações literais são verificados após a geração; falhas resultam em abstenção.

Evidências de execução

Comparação de recuperação

O protocolo contém oito perguntas: três de desenvolvimento e cinco de teste. Para cada método, os três primeiros documentos foram reunidos em um pool e julgados com escala 0 (irrelevante), 1 (parcial) e 2 (direto). Precision@3 considera notas 1 e 2 como relevantes.

MÉTODO	PRECISION@3	TOTALMENTE RELEVANTES@3
Lexical TF-IDF	100.0%	73.3%
Semântica	86.7%	66.7%
Híbrida RRF	93.3%	80.0%

Limite da medição

Os julgamentos foram produzidos com assistência de IA, sem anotador humano independente. O conjunto é pequeno e representa perguntas selecionadas, não a distribuição real de uso. Não foi calculado recall global porque não há julgamento de toda a base.

Testes e geração

29 testes automatizados aprovados verificam integridade de joins, preservação de negações, dados ausentes, recusas, IDs e citações inválidas, erro de infraestrutura. Quatro verificações adicionais via AppTest cobrem a interface. As respostas do modelo local são registradas integralmente com seus documentos e tempo total.

Geração: resultado final

Na demonstração, 8 de 8 decisões corresponderam ao esperado. Nas seis consultas adicionais reutilizadas, foram 4 de 6: duas perguntas respondíveis foram recusadas indevidamente. Não é um teste independente nem uma estimativa de acurácia geral.

Leitura crítica

Uma citação existente pode acompanhar uma síntese equivocada. A validação automática garante pertencimento e literalidade, mas não demonstra entailment semântico. O pequeno LLM pode omitir informação ou formular uma inferência inadequada. Revisão humana é necessária antes de decisões de negócio.

Arquivos: evaluation/queries.json, evaluation/qrels.json, evidence/retrieval_metrics.json, evidence/tests.txt e evidence/demo_runs.json.

Respostas com fontes visíveis

O que os clientes relatam sobre atrasos na entrega?

Há relato de demora na entrega

“demora na entrega”

Fonte: Dab27851cf3562820 · 19.261 s

Quais relatos mencionam produtos quebrados ou danificados?

Há relato de produtos quebrados ou danificados.

“produto veio danificado”

Fonte: D80652dae0f7e0d9b · 23.639 s

Quais elogios se referem à entrega antes do prazo?

Uma avaliação elogia a entrega antecipada

“entrega antes do prazo...”

Fonte: D2ae118cafbcdf0f2 · 21.851 s

Recusas e ausências de evidência

O que os clientes relatam sobre a entrega por drones? — abstenção

Qual é a capital da França? — abstenção

Como foi a entrega em 2026? — abstenção

Qual o percentual de clientes com atrasos? — abstenção

Há reclamações sobre a entrega? (categoria inexistente) — abstenção

Os exemplos acima foram obtidos na execução, não redigidos como se fossem respostas do sistema. As evidências completas, filtros e tempos estão no JSON da demonstração.

Uma solução que pode ser conferida

PASSO	ONDE CONFERIR
Instalar e preparar	README.md
Reproduzir a recuperação	scripts/evaluate_retrieval.py e evaluation/qrels.json
Reproduzir respostas	scripts/run_demo.py; LLM local deve estar disponível
Verificar requisitos	docs/MATRIZ_REQUISITOS.md

Escopo da validação

A execução de referência usa Linux, CPU e backend llama.cpp. A interface com Ollama foi verificada manualmente no Windows em três consultas: atrasos, elogios à entrega antecipada e pergunta fora do período da base. Versões, hashes e resultados estão em evidence/. Downloads iniciais exigem internet. Essa verificação pontual não substitui a avaliação quantitativa de referência.

Próximos passos técnicos

Ampliar perguntas e anotadores independentes; calibrar limiares de abstenção; testar reranker multilíngue; acrescentar classificação temática e agregação para frequências. Aplicações públicas exigiriam autenticação, controles de acesso e revisão de privacidade.

Fontes principais

Dados: Olist / Kaggle, Brazilian E-Commerce Public Dataset, licença CC BY-NC-SA 4.0. Modelos: Sentence Transformers / MiniLM multilíngue e Qwen2.5-3B-Instruct-GGUF, conforme model cards. Bibliografia e URLs completas: docs/REFERENCIAS.md. Requisitos acadêmicos: briefing [IAST] Tech Challenge Fase 4, pp. 6–10.

O bônus opcional Databricks não integra o escopo implementado; não há reivindicação de bonificação.